CS 287: Advanced Robotics

Geonhee Lee
gunhee6392@gmail.com

Lecture 1: Introduction

성공적인 robotic stories 및 이 강좌에서 다루는 material과 연결.

1. Driverless Cars *[Darpa Grand Challenge, Darpa Urban Challenge, Google Self-Driving Car, ...]*
    - Kalman filtering, LQR, mapping, terrain & object recognition.
2. Autonomous Helicopter Flight *[Abbeel, Coates & Ng]*
    - Kalman filtering, model-predictive control, LQR, system ID, trajectory learning.
3. Four-legged locomotion *[Kolter, Abbeel & Ng]*
    - value iteration, receding horizon control, motion planning, inverse reinforcement learning, nolearning, learned.
4. Two-legged locomotion *[Tedrake +al.]*
    - Policy gradient.
5. Mapping
    - FastSLAM: particle filter + occupancy grid mapping.
6. Mobile Manipulation *[Quigley, Gould, Saxena, Ng + al.]* , *[Maitin-Shepard, Cusumano-Towner, Lei, Abbeel, 2010]*
    - SLAM, localization, motion planning for navigation and grasping, grasp point selection, visual category recognition (speech recognition and synthesis)
    - localization, motion planning for navigation and grasping, grasp point selection, visual recognition
7. Visuomotor Learning *[Levine*, Finn*, Darrell, Abbeel, 2015]*
    - LQR, guided policy search, deep learning
8. Learned Visuomotor Skills *[Levine*, Finn*, Darrell, Abbeel, 2015]*
    - LQR, guided policy search, deep learning
9. Learning Locomotion *[Schulman, Moritz, Levine, Jordan, Abbeel, 2015]*

- policy gradients, value function approximation

Why a Great Time to Study CS287 Advanced Robotics?

- 다양한 robotic 시스템이 있지만, 몇 가지 핵심 기술이면 충분하다.
    - Probabilistic Reasoning
    - Optimization
- 이러한 기술의 응용은 robotics를 넘어 잘 확장됨

Lecture 2: Markov Decision Processes and Exact Solution Methods: Value Iteration, Policy Iteration, Linear Programming

Markov Decision Process (S, A, T, R, γ , H)

- 가정: Agent는 state를 관측하게 된다.

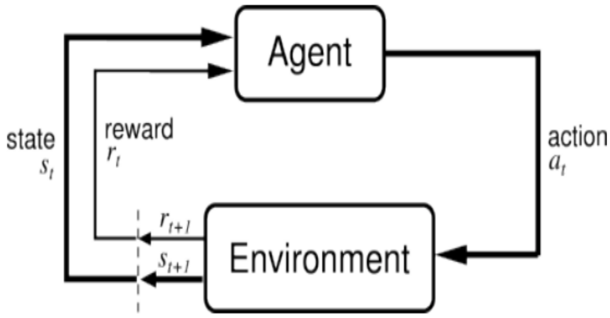

Given

- S: state 집합
- A: action 집합
- T: S x A x S x {0, 1, ..., H} $\rightarrow$ [0, 1]
  - T$_t$ (s, a, s') = P ($s_{t+1} = s' | s_t, a_t = a$)
- R: S x A x S x {0, 1, ..., H} $\rightarrow \mathbb{R}$
  - R$_t$ (s, a, s') = reward for ($s_{t+1} = s', s_t, s_t = sa_t = a$)
- γ in (0, 1]: discount factor
- H: agent가 행동하게 될 horizon

Goal

- π^* 찾기 $\rightarrow$ expected sum of reward를 최대화 하는 것 : S x {0, 1, ..., H}, i.e.,

$$\pi^* = \arg\max_{\pi} \mathrm{E}[\sum_{t=0}^{H} \gamma^t R_t(S_t, A_t, S_{t+1}) | \pi]$$

Solving MDPs

- MDP에서, **optimal policy (π^* : S x 0:H $\rightarrow$ A**)를 찾기를 원함.
  - Policy π 는 각 time에서 각 state에 대한 action을 제공.
  - Optimal policy는 expected sum of rewards를 최대화.
- 차이: deterministic이라면, 시작점부터 목표지점까지 optimal **plan** (혹은 action의 sequence)가 필요함.

Outline

- Optimal Control

  =

  given an MDP (S, A, T, R, γ, H)

  find the optimal policy π^*

- Exact Methods:
  - ***Value Iteration***
  - Policy Iteration
  - Linear Programming

지금까지 다룬 descrete state-action space는 주요 개념을 이해하기 더욱 쉬웠고, 이후 continous space를 나중에 고려할 것.

Value Iteration

Algorithm:

Start with $V_0^*(s) = 0$ for all s.

For i = 1, … , H

For all states s in S:

$$V_{i+1}^*(s) \leftarrow \max_a \sum_{s'} T(s,a,s') \left[R(s,a,s') + \gamma V_i^*(s')\right]$$

$$\pi_{i+1}^*(s) \leftarrow \arg\max_{a \in A} \sum_{s'} T(s,a,s') \left[R(s,a,s') + \gamma V_i^*(s')\right]$$

This is called a value update or Bellman update/back-up

$V_i^*(s)$ = expected sum of rewards accumulated starting from state s, acting optimally for i steps

$\pi_i^*(s)$ = optimal action when in state s and getting to act for i steps

Value Iteration Convergence

> Theorem. Value iteration은 수렴.
>
> > 수렴지점에서, Bellman equation을 만족하는 discounted infinite horizon 문제에 대해서 optimal value function V^* 을 찾는다.

$$\forall S \in S: \quad V^*(s) = \max_A \sum_{s'} T(s,a,s') \left[R(s,a,s') + \gamma V^*(s')\right]$$

- Discounted reward를 가진 infinite horizon에 대해 어떻게 행동해야지 안다
  - 수렴할때까지 value iteration을 실행.
  - $V ^를생성하고,V ^$ 는 다음과 같이 행동하는 방법을 알려준다.

$$\pi^*(s) = \arg\max_{a \in A} \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma V^*(s')]$$

- Note: infinite horizon optimal policy는 stationary, 즉, 각 state s에서 optimal action은 항상 같은 action. (저장하기 효율적)

Convergence: Intuition

- $V^*(s)$ = state s에서부터 ∞ step에서 optimally 행동하여 축적되는 보상의 expected 합.
- $V_H^*(s)$ = state s에서부터 H step동안 축적되는 보상의 expected 합.

추가적으로 다음 horizon에 걸쳐 수집되는 보상들이 있으며, H가 무한대로 가게되면, $V_H^*(s)$ 는 $V^*(s)$ 이 된다.

Convergence and Contractions

- max-norm 정의: $|U|$ = max $_x|U(s)|$

> Theorem: 두 개의 근사 U, V에 대하여,
>
> > $|U_{i+1} - V_i| \leq \gamma |U_i - V_i|$ 즉, 어떤 구별된 근사화는 더욱더 가까워져야하고, 특히,

Policy Evaluation

Policy Iteration

Lecture3 (Discretization)

Continious State Spaces

- S = continuous set
- Value iteration은 모든 state들에 대해서 계산하기에는 비현실적(불가능).

Markov chain approximation을 통해 continousous state space dynamics model로 변환("discretization) - Grid the state-space: vertice(꼭지점, 정점)가 discrete state. - action space를 finite set으로 축소 - 어떤 경우들에서는 필요가 없다 - Bellman back-up이 continous action space에 걸쳐 정확히 계산될때. - optimal policy의 부분인 오직 하니의 특정 제어를 알때. - Transition function은 이후에 다룰것.

Reference

1. CS 287 - Advanced Robotics